

FLASC: Aprendizado Federado com Agrupamento Suave Adaptativo para Minimização do Impacto da Heterogeneidade de Dados

Pedro Gabriel do Valle Nogueira¹

¹ Programa de Pós-Graduação em Engenharia Eletrônica
Universidade do Estado do Rio de Janeiro (UERJ) – Rio de Janeiro, RJ – Brasil

Resumo. *O Aprendizado Federado (FL) enfrenta desafios devido à heterogeneidade estatística dos dados distribuídos. O método FLSC minimiza esse impacto ao permitir que clientes participem de múltiplos clusters simultaneamente, entretanto, utiliza parâmetros fixos e pesos uniformes. Este trabalho propõe o FLASC (Federated Learning with Adaptive Soft Clustering), uma abordagem que introduz a seleção adaptativa de modelos baseada em um limiar de tolerância e a fusão ponderada pela perda local. Essa estratégia permite que o nível de participação e a influência de cada modelo se ajustem dinamicamente à distribuição de dados de cada cliente. Testes com o conjunto CIFAR-10 mostram que o FLASC atinge resultados similares ao estado da arte.*

Abstract. *Federated Learning (FL) faces challenges due to statistical heterogeneity of distributed data. The FLSC method minimizes this impact by allowing clients to participate in multiple clusters simultaneously; however, it relies on fixed parameters and uniform weights. This work proposes FLASC (Federated Learning with Adaptive Soft Clustering), an approach that introduces adaptive model selection based on a tolerance threshold and weighted fusion through local loss. This strategy allows the participation level and the influence of each model to dynamically adjust to each client's data distribution. Tests with the CIFAR-10 dataset show that FLASC achieves results similar to the state-of-the-art.*

1. Introdução

A crescente digitalização de serviços e a onipresença de dispositivos computacionais pessoais gera um volume de dados distribuídos sem precedentes, o que impulsiona o desenvolvimento de soluções baseadas em aprendizado de máquina (ML). Tradicionalmente, uma solução de ML exige que os dados estejam em um único dispositivo. No entanto, os dados distribuídos geralmente devem permanecer nos seus dispositivos de origem por questões de privacidade. Para superar esse obstáculo, o Aprendizado Federado (do inglês, *Federated Learning* – FL) surgiu como um paradigma onde um servidor mantém um modelo global e distribui cópias para clientes selecionados na rede. Nessa arquitetura, os dispositivos realizam o treinamento local com seus próprios dados e transmitem apenas as atualizações dos parâmetros. O servidor então agrega essas contribuições via média ponderada (FedAvg) para atualizar o modelo global. Todo esse processo se repete por diversas rodadas visando a convergência [1].

Apesar dos avanços que o FL proporcionou para sistemas de recomendação e para a área da saúde, sua eficácia é frequentemente desafiada pela heterogeneidade estatística

dos dados nos clientes, conhecida como dados não-IID [2]. Essa heterogeneidade impacta negativamente a agregação, tornando o modelo global subótimo para a maioria dos participantes. Com o objetivo de solucionar esse problema, uma linha de pesquisa proeminente foca no Aprendizado Federado Clusterizado (do inglês, *Clustered Federated Learning* – CFL). A intuição por trás do CFL é agrupar clientes com distribuições de dados semelhantes e treinar modelos especializados para cada grupo. Essa abordagem tem demonstrado melhorar significativamente o desempenho em ambientes heterogêneos.

No IFCA, método de CFL proposto por Ghosh et al. [3], o servidor mantém múltiplos modelos globais e os transmite aos clientes. Cada participante avalia os modelos recebidos com seus próprios dados e seleciona aquele que possui menor perda como base para o treinamento local. Terminado o treinamento, o cliente envia o modelo treinado de volta para o servidor junto do identificador de qual modelo usou. No servidor, cada modelo global é atualizado somente com os clientes que os utilizaram para treinar. O IFCA exige que o cliente se identifique estritamente com um grupo por rodada, o que limita a possibilidade de usar conhecimento de outros grupos localmente. Isso também limita a contribuição do cliente na atualização dos modelos globais, já que apenas o modelo do grupo selecionado será beneficiado.

Li et al. [4] apresentam o Aprendizado Federado com Agrupamento Suave (FLSC) como uma evolução do IFCA. Nesse método, os clientes selecionam um número fixo N de modelos e transmitem ao servidor a lista com seus respectivos identificadores. Essa abordagem permitiu que os participantes pertencessem a múltiplos grupos simultaneamente e, graças a essa flexibilidade, o FLSC demonstrou capturar melhor a natureza dos dados não-IID. Contudo, o método impõe que todos os clientes participem de uma quantidade rígida de grupos, atribuindo sempre o mesmo peso de participação a cada um deles. Isso ainda não reflete fielmente um cenário real. Por exemplo, em um sistema de recomendação, um cliente c_1 pode possuir conteúdos apenas dos tipos A e B, enquanto outro cliente c_2 detém conteúdos dos tipos B, C, D e E. É natural supor que c_1 deva participar de menos grupos de recomendação que c_2 . Além disso, os conteúdos não são necessariamente consumidos com a mesma frequência; se c_2 consome predominantemente o tipo B, faz sentido que ele participe com maior peso do grupo que contempla essa categoria específica.

Visando superar as limitações do FLSC, este trabalho propõe o FLASC (*Federated Learning with Adaptive Soft Clustering*). Diferente do FLSC, o FLASC permite não só que a quantidade de grupos que um cliente participe se ajuste conforme a sua distribuição local, como ele também pondera o peso de participação do cliente em cada grupo. Experimentos realizados com o conjunto de dados CIFAR-10 [5] em um cenário de heterogeneidade estatística demonstram que o FLASC alcança resultados de acurácia e perda comparáveis ao FLSC.

O restante deste trabalho está organizado da seguinte forma: a Seção 2 descreve detalhadamente o funcionamento do algoritmo FLASC; a Seção 3 detalha a metodologia de avaliação e o ambiente experimental; a Seção 4 apresenta a análise dos resultados obtidos; e, finalmente, a Seção 5 traz as considerações finais e propostas para trabalhos futuros.

2. FLASC

Esta seção detalha o funcionamento do algoritmo FLASC, descrevendo os mecanismos de seleção adaptativa e fusão ponderada que o diferenciam do FLSC. O Algoritmo 1 detalha o fluxo operacional completo do processo de treinamento federado.

Algoritmo 1: Algoritmo FLASC

Input: Parâmetros iniciais K , tolerância ρ , sensibilidade ϵ
Data: Conjuntos de dados locais $\mathcal{D}_c$ nos clientes

- 1 **Servidor:** Inicializa $\mathcal{W}_1 = \{W_{1,1}, \dots, W_{K,1}\}$;
- 2 **for** cada rodada $t = 1, \dots, T$ **do**
- 3 Servidor seleciona aleatoriamente um subconjunto de clientes P_t ;
- 4 Servidor transmite $\mathcal{W}_t$ para todos os clientes em P_t ;
- 5 **Cada cliente** $c \in P_t$ **em paralelo:**
- 6 Calcula perdas locais $L_{c,i} = \text{EntropiaCruzada}(W_{i,t}, \mathcal{D}_c)$ para
 $i \in \{1, \dots, K\}$;
- 7 $L_{\min} \leftarrow \min_i \{L_{c,i}\}$, $L_{\max} \leftarrow \max_i \{L_{c,i}\}$;
- 8 **if** $L_{\max} - L_{\min} \leq \epsilon$ **then**
- 9 $i' \sim \text{Unif}\{1, \dots, K\}$, $S_c \leftarrow \{i'\}$;
- 10 $\alpha_{c,i'} \leftarrow 1$;
- 11 **else**
- 12 $\hat{L}_{c,i} \leftarrow \frac{L_{c,i} - L_{\min}}{L_{\max} - L_{\min}}$ para cada $i \in \{1, \dots, K\}$;
- 13 $S_c \leftarrow \{i \mid \hat{L}_{c,i} \leq \rho\}$;
- 14 $\alpha_{c,i} \leftarrow \frac{1 - \hat{L}_{c,i}}{\sum_{j \in S_c} (1 - \hat{L}_{c,j})}$ para cada $i \in S_c$;
- 15 **end**
- 16 $W_{c,t} \leftarrow \sum_{i \in S_c} \alpha_{c,i} W_{i,t}$;
- 17 $W_{c,t}^{\text{end}} \leftarrow \text{TreinamentoLocal}(W_{c,t}, \mathcal{D}_c)$;
- 18 Envia $\{W_{c,t}^{\text{end}}, S_c\}$ para o servidor;
- 19 **Servidor:**
- 20 **for** cada cluster $i \in \{1, \dots, K\}$ **do**
- 21 **if** $\{c \in P_t \mid i \in S_c\} \neq \emptyset$ **then**
- 22 $W_{i,t+1} \leftarrow \frac{\sum_{c \in \{j \in P_t \mid i \in S_j\}} |\mathcal{D}_c| W_{c,t}^{\text{end}}}{\sum_{c \in \{j \in P_t \mid i \in S_j\}} |\mathcal{D}_c|}$;
- 23 **else**
- 24 $W_{i,t+1} \leftarrow W_{i,t}$;
- 25 **end**
- 26 **end**
- 27 **end**

Tanto o FLASC quanto o FLSC gerenciam um conjunto de K modelos globais no servidor, representados por $\mathcal{W}_t = \{W_{1,t}, W_{2,t}, \dots, W_{K,t}\}$. No início de cada rodada de treinamento, o servidor seleciona uma fração de clientes para participação e realiza a transmissão de $\mathcal{W}_t$. Uma vez recebidos os modelos, cada participante c mensura o

desempenho de cada modelo calculando a Entropia Cruzada em relação ao seu conjunto de dados local $\mathcal{D}_c$ (Linha 6).

2.1. Seleção dos modelos no cliente

A partir das perdas calculadas, o FLASC avalia a amplitude entre a maior e a menor perda (Linha 8). Se essa diferença for inferior ao limiar de sensibilidade ϵ , os modelos são considerados indistinguíveis para o cliente e um único modelo é selecionado aleatoriamente (Linha 9). Caso contrário, as perdas são normalizadas no intervalo $[0, 1]$ (Linha 12).

Em seguida, define-se o conjunto S_c dos índices dos modelos selecionados através do limiar $\rho \in [0, 1]$ (Linha 13). Este limiar estabelece um teto de tolerância para as perdas, assegurando que apenas os modelos com desempenho suficientemente próximo ao melhor candidato componham o conjunto de fusão. Diferentemente do FLSC, onde o tamanho do conjunto de seleção N é fixado a priori, o FLASC permite uma seleção adaptativa, evitando a inclusão de modelos com erros excessivos apenas para satisfazer uma restrição de cardinalidade. Adicionalmente, para cada modelo selecionado, o FLASC atribui um peso de contribuição $\alpha_{c,i}$ que decresce linearmente em função da perda normalizada (Linhas 10 e 14). Este mecanismo garante que modelos com menor erro local exerçam maior influência na fusão, funcionalidade que não é contemplada na formulação original do FLSC.

2.2. Fusão, treinamento e agregação

Concluída a etapa de seleção, o cliente sintetiza o modelo inicial para o treinamento local $W_{c,t}$ mediante uma média ponderada (Linha 16). Após o treinamento local, os parâmetros atualizados ($W_{c,t}^{end}$) são devolvidos ao servidor acompanhados de S_c (Linhas 17-18). Ao término da rodada, o servidor atualiza os modelos globais de forma independente (Linhas 20-26). Para cada cluster i , a nova versão $W_{i,t+1}$ é obtida por meio de uma média ponderada das atualizações enviadas pelos clientes que usaram o respectivo modelo em sua fusão local. Caso $W_{i,t}$ não tenha sido selecionado por nenhum cliente, seus parâmetros permanecem inalterados.

3. Proposta de avaliação

Esta seção apresenta a metodologia experimental utilizada para avaliar o desempenho do FLASC, incluindo o objetivo da avaliação, os parâmetros, a distribuição dos dados, o protocolo de avaliação e as tecnologias utilizadas.

A avaliação proposta visa quantificar o impacto de substituir o parâmetro rígido de seleção N pelo limiar ρ . Conforme detalhado na Tabela 1, os hiperparâmetros de ambos os algoritmos variam de forma correlacionada para permitir uma comparação em cenários de seleção unitária até inclusão total de modelos ($K = 4$). O hiperparâmetro ϵ do FLASC foi fixado em 1×10^{-5} .

Tabela 1. Mapeamento de hiperparâmetros para comparação entre FLSC e FLASC.

Cenário de Seleção	FLSC (N)	FLASC (ρ)
Mínima	1	0
Intermediária (metade)	2	0,5
Máxima	4	1

Para simular um ambiente de heterogeneidade de dados, foi utilizado o conjunto de dados CIFAR-10 [5] distribuído via partição de Dirichlet com $\alpha = 0, 1$. No total, a simulação compreende 10 clientes participando de 10 rodadas de treinamento, com cada nó reservando 20% de seus dados locais para a etapa de avaliação.

Quanto à simulação em si, foi utilizado o framework Flower (v1.24.0) [6] integrado à biblioteca PyTorch [7]. A arquitetura dos modelos consiste em uma rede neural convolucional (CNN) de duas camadas de convolução (6 e 16 filtros de 5×5 , respectivamente) intercaladas por *max-pooling*, seguidas por três camadas densas. O treinamento foi conduzido com otimizador SGD (momento 0,9), taxa de aprendizado de 0,001 e *batch size* de 32. Em cada rodada, os clientes executam 3 épocas de treinamento local antes de reportar as atualizações ao servidor. O código completo e os scripts de reprodução estão disponíveis no GitHub¹.

3.1. Protocolo de avaliação

Ao final de cada rodada de treinamento, o servidor transmite os K modelos globais atualizados para os clientes selecionados. Cada nó avalia individualmente o desempenho de todo o conjunto $\mathcal{W}_t$ em seu conjunto de teste local e identifica o modelo que apresenta a menor perda empírica. Uma vez identificado o melhor candidato, o cliente reporta a acurácia e a perda deste modelo específico ao servidor. As métricas globais são então obtidas através da média ponderada dessas respostas.

3.2. Expectativas

No cenário de seleção mínima ($\rho = 0$ e $N = 1$), antecipa-se que ambos os algoritmos apresentem desempenhos similares, uma vez que ambos selecionam apenas o modelo de melhor desempenho local. Contudo, a hipótese central deste trabalho é que o FLASC apresentará melhores resultados nos demais cenários por dois motivos principais:

1. **Adaptabilidade da seleção:** No cenário intermediário ($\rho = 0,5$), enquanto o FLSC é forçado a incluir exatamente $N = 2$ modelos, o FLASC sabe determinar quantos modelos possuem uma perda aceitável para integrar a fusão baseado em ρ . Espera-se que isso evite modelos com desempenho ruim de degradarem o treinamento local e a agregação global.
2. **Fusão ponderada:** No cenário de seleção máxima ($\rho = 1$ e $N = 4$) (e também no anterior), espera-se que a atribuição de pesos maiores para modelos com menor perda (Linha 14 do Algoritmo 1) resulte em uma convergência mais rápida.

3.3. Reprodutibilidade

Devido à natureza estocástica do aprendizado federado, foram adotadas medidas para assegurar a reprodutibilidade dos experimentos. O controle de aleatoriedade foi implementado por meio da fixação de sementes em componentes críticos, incluindo no particionamento dos dados entre os clientes, na inicialização dos pesos das redes e nas sub-rotinas de treinamento e avaliação. Cada cenário descrito na Tabela 1 foi submetido a cinco execuções independentes, utilizando o conjunto de sementes $\{42, 43, 44, 45, 46\}$.

¹<https://github.com/pgvalle/SimuAprendizadoFederado>

4. Resultados

Esta seção discute os resultados da avaliação de desempenho proposta na Seção 3. Os gráficos mostram a média das cinco execuções independentes, com as barras de erro indicando o desvio padrão. A análise foca em como a substituição do parâmetro N pelo parâmetro ρ impacta as métricas de avaliação.

4.1. Cenário de Seleção Mínima ($\rho = 0$ e $N = 1$)

As Figuras 1 e 2 ilustram a acurácia e a perda de avaliação para o cenário de seleção mínima. Nesta configuração, o FLASC é restringido a selecionar apenas o modelo com a menor perda local ($\rho = 0$), replicando exatamente a lógica de seleção rígida do FLSC com $N = 1$. Os resultados apontam que, em um regime de seleção unitária, o uso do ρ mantém desempenho similar ao da linha de base conforme teorizado na Seção 3.




Figura 1. Evolução da acurácia de avaliação no cenário de seleção mínima ($\rho = 0$, $N = 1$).




Figura 2. Evolução da perda de avaliação no cenário de seleção mínima ($\rho = 0$, $N = 1$).

4.2. Cenário de Seleção Intermediária ($\rho = 0,5$ e $N = 2$)

No cenário intermediário, as Figuras 3 e 4 mostram que o FLASC e o FLSC mantiveram comportamentos similares. Havia a expectativa de que o limiar adaptativo ρ permitisse um refinamento na seleção, filtrando modelos com desempenho marginal e favorecendo a estabilidade. Entretanto, a imposição de um número fixo de modelos ($N = 2$) no FLSC não se mostrou prejudicial.




Figura 3. Evolução da acurácia de avaliação no cenário intermediário ($\rho = 0,5$, $N = 2$).




Figura 4. Evolução da perda de avaliação no cenário intermediário ($\rho = 0,5$, $N = 2$).

4.3. Cenário de Seleção Máxima ($\rho = 1$ e $N = 4$)

Para o cenário de seleção máxima, as Figuras 5 e 6 revelam que a ponderação das perdas na fusão local não proporcionou ganhos significativos ao FLASC. Embora a hipótese central fosse de que priorizar modelos com melhor adaptação local resultaria em uma convergência acelerada, os dados indicam que tanto a média ponderada quanto a média simples (FLSC) convergem para patamares de acurácia equivalentes.




Figura 5. Evolução da acurácia de avaliação no cenário de seleção máxima ($\rho = 1, N = 4$).




Figura 6. Evolução da perda de avaliação no cenário de seleção máxima ($\rho = 1, N = 4$).

Em suma, os resultados mostram que a troca da seleção de tamanho fixo pelo mecanismo adaptativo proposto, embora ofereça maior flexibilidade teórica, não resultou em diferença expressiva de desempenho no cenário experimental avaliado.

5. Considerações Finais e Trabalhos Futuros

Neste trabalho, apresentamos o FLASC, uma extensão do algoritmo FLSC que introduz um limiar adaptativo ρ para a seleção de modelos e uma fusão local ponderada pela perda empírica. A motivação central foi proporcionar maior flexibilidade de agrupamento ao permitir que a quantidade e a influência de cada submodelo global fossem determinadas dinamicamente com base no desempenho local.

Os resultados experimentais conduzidos sobre o conjunto de dados CIFAR-10, em um cenário de heterogeneidade estatística, revelaram que o FLASC mantém um desempenho equivalente ao FLSC. Embora a hipótese inicial de que a seleção adaptativa e a ponderação de perdas se traduziria em ganhos significativos, o FLASC demonstrou que a mudança de abordagem não foi inviável no cenário avaliado.

Como possibilidades para trabalhos futuros, propõem-se as seguintes frentes de investigação:

- **Mais rodadas de treinamento:** Avaliar a convergência do FLASC em simulações de maior duração (ex: 20 a 50 rodadas) para verificar se vantagens da fusão adaptativa se revelam em treinamentos prolongados.
- **Exploração extensiva de hiperparâmetros:** Conduzir um estudo que explore mais o parâmetro ρ para avaliar melhor seu impacto no treinamento.
- **Diversificação do particionamento de dados:** Testar o algoritmo sob outras configurações de heterogeneidade.

Referências

- [1] Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Agüera y Arcas. Communication-efficient learning of deep networks from decentralized data. In *Artificial intelligence and statistics*, pages 1273–1282. Pmlr, 2017.
- [2] Tzu-Ming Harry Hsu, Hang Qi, and Matthew Brown. Measuring the effects of non-identical data distributions for federated learning. *arXiv preprint arXiv:1909.06335*, 2019.
- [3] Avishek Ghosh, Jichan Chung, Dong Yin, and Kannan Ramchandran. An efficient framework for clustered federated learning. *Advances in neural information processing systems*, 33:19586–19597, 2020.
- [4] Chengxi Li, Gang Li, and Pramod K Varshney. Federated learning with soft clustering. *IEEE Internet of Things Journal*, 9(10):7773–7782, 2021.
- [5] Alex Krizhevsky and Geoffrey Hinton. The cifar-10 dataset. <https://www.cs.toronto.edu/~kriz/cifar.html>, 2009. Acessado em: 26 fev. 2026.
- [6] Daniel J. Beutel et al. Flower: A friendly federated learning framework. <https://flower.ai/>, 2020. Acessado em: 26 fev. 2026.
- [7] Adam Paszke et al. Pytorch. <https://pytorch.org/>, 2019. Acessado em: 26 fev. 2026.